Diseño de solución con LLM y RAG para atención primaria municipal

Informe técnico de propuesta e implementación

Campo	Detalle
Caso	Asistente RAG para la Dirección de Salud Municipal de Santa Isabel
Asignatura	Desarrollo de Agentes Inteligentes con LLM
Integrantes	Completar con nombres del equipo
Fecha	Septiembre de 2026
Producto	Informe técnico, repositorio de código y presentación de defensa

Este documento presenta un caso organizacional contextualizado y una solución técnica basada en LLM, agentes inteligentes y recuperación aumentada de información. El diseño prioriza trazabilidad, seguridad, control de datos sensibles y utilidad operativa para funcionarios de atención primaria.

Resumen ejecutivo

La Dirección de Salud Municipal de Santa Isabel administra tres CESFAM, un SAPU y una unidad de atención telefónica. Sus funcionarios responden consultas sobre horas médicas, farmacia, derivaciones, derechos de pacientes y contingencias operativas. La información se encuentra dispersa entre protocolos, circulares internas, planillas y correos, lo que genera respuestas inconsistentes y dependencia de personas expertas.

Se propone un asistente interno basado en LLM y RAG. El sistema recupera fragmentos relevantes desde una base documental controlada, construye un contexto citando fuentes y genera una respuesta breve para el funcionario. Además, incorpora guardrails para bloquear urgencias, evitar consejo clínico personalizado, anonimizar datos personales y derivar a responsables humanos cuando la evidencia sea insuficiente.

El principal valor del diseño no consiste en automatizar toda la atención, sino en ordenar la información institucional y disminuir variabilidad en consultas administrativas. En salud, la respuesta correcta muchas veces es reconocer el límite del asistente y escalar el caso.

Caso organizacional

Institución contextualizada

Santa Isabel es una comuna urbana ficticia de tamaño medio. Su red de atención primaria incluye tres CESFAM, un SAPU y un equipo comunal de atención remota. El caso es contextualizado, pero sus procesos se basan en situaciones habituales de atención primaria municipal: SOME, agenda, farmacia, derivaciones, lista de espera, derechos de pacientes y resguardo de ficha clínica.

Dolor organizacional

- La información operativa se actualiza por múltiples canales y no siempre llega a todos los turnos.
- Funcionarios nuevos dependen de colegas expertos para responder consultas frecuentes.
- Las respuestas por teléfono, mesón y correo pueden variar aunque traten el mismo procedimiento.
- Existe riesgo de solicitar o repetir datos sensibles en espacios no autorizados.
- Las consultas clínicas ambiguas pueden recibir orientación administrativa incorrecta si no se escalan.

Objetivos de intervención

- Centralizar conocimiento operativo vigente en una base documental recuperable.
- Generar respuestas con citas a fuentes internas para mejorar trazabilidad.
- Reducir alucinaciones obligando al LLM a responder solo con contexto recuperado.
- Proteger datos personales y ficha clínica mediante anonimización y control de acceso.
- Escalar preguntas sin evidencia, con riesgo clínico o con solicitudes de terceros no autorizados.

Fuentes de datos

La solución no utiliza ficha clínica ni información identificable de pacientes. Se alimenta con documentos operativos aprobados por responsables internos. Cada fuente debe tener dueño, versión, fecha de vigencia, clasificación de sensibilidad y estado de aprobación.

Fuente	Contenido	Responsable	Sensibilidad	Uso en RAG
Protocolo de agenda	Toma y cambio de horas, contingencias	SOME comunal	Media	Orientación administrativa
Protocolo de farmacia	Retiro crónico, receta vigente, quiebres	Químico farmacéutico	Media	Respuesta con restricciones
Derechos de pacientes	Información, confidencialidad, ficha clínica	Calidad y OIRS	Alta	Reglas y derivación
Derivaciones	Estado administrativo y escalamiento	Lista de espera	Media	Consulta de estado
Continuidad operativa	Caída de sistemas y auditoría	TI municipal	Media	Plan de contingencia

Tabla 1. Fuentes documentales internas consideradas para el caso.

Diseño técnico de la solución

Arquitectura general

La arquitectura separa el canal de usuario, los controles de entrada, la recuperación documental, la construcción del contexto, el generador LLM, el verificador de salida y la auditoría. Esta separación permite probar cada componente de forma independiente y evita que el modelo opere como una caja negra.

Capa	Función	Control principal
Interfaz	Chat interno para funcionarios	Autenticación institucional y rol del usuario
Guardrail de entrada	Clasifica intención y anonimiza datos	Bloqueo de urgencias y datos personales
Retriever	Busca chunks relevantes	Top k, umbral mínimo, documentos vigentes
Constructor de contexto	Ordena evidencia y citas	Separación entre instrucciones y datos
Generador LLM	Redacta respuesta operacional	Temperatura baja y prompt con restricciones
Verificador	Revisa respaldo y política de salida	Derivación si falta evidencia
Auditoría	Registra decisión sin datos sensibles	Trazabilidad y mejora continua

Tabla 2. Componentes de arquitectura y controles asociados.

Flujo lógico: Funcionario -> chat interno -> guardrail de entrada -> recuperación documental -> contexto citado -> LLM generador -> verificador -> respuesta o escalamiento -> auditoría.

Pipeline RAG

RAG se justifica porque los LLM pueden producir respuestas plausibles pero no necesariamente verificables. La literatura original de RAG plantea combinar memoria paramétrica del modelo con memoria no paramétrica recuperada desde una fuente externa para mejorar especificidad, actualización y factualidad (Lewis et al., 2020). Revisiones posteriores destacan que RAG ayuda frente a alucinación, conocimiento obsoleto y falta de trazabilidad, aunque introduce desafíos de recuperación, evaluación y seguridad (Gao et al., 2024).

Etapa	Entrada	Proceso	Salida
Ingesta	Protocolos internos	Normalización, metadatos, control de versión	Documentos aprobados
Chunking	Secciones del documento	División semántica por subtítulos	Fragmentos citables
Indexación	Chunks	BM25 en demo, embeddings en producción	Índice recuperable
Recuperación	Pregunta anonimizada	Top k con umbral mínimo	Evidencia candidata
Generación	Pregunta y contexto	Prompt con reglas y citas obligatorias	Respuesta preliminar
Verificación	Respuesta y fuentes	Chequeo de evidencia, riesgo y política	Respuesta o derivación

Tabla 3. Pipeline RAG propuesto.

Agentes inteligentes

El sistema se modela como una arquitectura multiagente liviana. No se otorga autonomía transaccional al modelo; cada agente cumple una función delimitada y observable. Esta decisión toma la idea de combinar razonamiento y acción de enfoques como ReAct, pero la adapta a un entorno de bajo riesgo operacional: el agente puede recuperar, redactar y escalar, pero no modificar agenda ni ficha clínica por sí mismo (Yao et al., 2023).

Agente	Responsabilidad	Herramienta	Criterio de éxito
Clasificador	Identifica intención y riesgo	Reglas y modelo liviano	Ruta correcta de atención
Recuperador	Busca evidencia vigente	BM25 o búsqueda híbrida	Fuente pertinente en top 3
Redactor	Construye respuesta citada	LLM con prompt controlado	Respuesta clara y sin invención
Verificador	Evalúa salida y política	Reglas de seguridad	Bloqueo o derivación correcta
Auditor	Registra trazabilidad	Log anonimizado	Registro útil sin datos sensibles

Tabla 4. Agentes propuestos para la solución.

Gestión del contexto conversacional

El asistente conserva la pregunta actual, la ruta de seguridad, las fuentes recuperadas y un resumen operativo de los últimos turnos. No mantiene datos personales persistentes. Si el usuario introduce RUT, teléfono, correo o información de ficha clínica, el texto se anonimiza antes de búsqueda y auditoría.

Prompts optimizados

Los prompts se separan por rol para disminuir ambigüedad. El sistema establece identidad, alcance y prohibiciones. El prompt de recuperación transforma la consulta en búsqueda documental. El prompt de respuesta obliga a citar fuentes. El prompt de verificación decide si la respuesta sale o se deriva.

Prompt	Fragmento propuesto	Justificación
Sistema	Responde solo con evidencia recuperada. No diagnostiques, no indiques tratamientos, no inventes horarios.	Fija límites antes de recibir datos variables y reduce respuestas fuera de alcance.
Recuperación	Transforma la pregunta en una búsqueda breve y elimina RUT, correos, teléfonos y datos identificables.	Mejora recall y protege datos personales antes de consultar índices.
Respuesta	Usa solamente el contexto recuperado y cita fuentes con el formato [DOCUMENTO - sección].	Hace verificable la respuesta y facilita auditoría posterior.
Verificación	Si no hay evidencia suficiente o la pregunta pide indicación clínica, deriva a responsable humano.	Controla alucinación, exceso de confianza y riesgo sanitario.
Escalamiento	Indica el canal humano correspondiente: SOME, farmacia, jefatura de sector, profesional clínico o urgencia.	Convierte el rechazo en una acción útil para el funcionario.

Tabla 5. Prompts y justificación técnica.

Implementación del prototipo

El repositorio incluido implementa una demo funcional sin servicios externos. Usa documentos ficticios en Markdown, chunking por secciones y recuperación BM25 escrita en Python. La respuesta se genera de forma determinística para que la evaluación pueda ejecutarse sin llaves de API. En producción, el componente de generación se reemplazaría por un LLM institucional manteniendo los mismos contratos de entrada y salida.

Archivo	Rol	Relevancia para la evaluación
src/salud_rag/documents.py	Carga y chunking	Muestra preparación de fuentes RAG
src/salud_rag/retrieval.py	BM25	Implementa recuperación sin dependencia externa
src/salud_rag/guardrails.py	Seguridad	Bloquea urgencias y anonimiza datos
src/salud_rag/prompts.py	Prompting	Separa sistema, contexto e instrucciones
src/salud_rag/pipeline.py	Orquestación	Une guardrails, retriever y respuesta
tests/test_pipeline.py	Pruebas	Valida recuperación y controles clave

Tabla 6. Componentes del prototipo.

Seguridad, privacidad y cumplimiento

La propuesta asume que los datos de salud son sensibles y que la ficha clínica requiere reserva. En Chile, la Ley N° 20.584 regula derechos y deberes de las personas en acciones vinculadas a su atención de salud, incluyendo acceso, información y reserva de ficha clínica. La Ley N° 19.628 define datos sensibles, y la Ley N° 21.719 moderniza el marco de protección de datos personales y entra en vigencia el 1 de diciembre de 2026, por lo que la solución se diseña con enfoque preventivo de cumplimiento.

El marco de riesgos toma como referencia NIST AI RMF 1.0, que propone gestionar sistemas de IA con foco en riesgos para personas, organizaciones y sociedad. Además, el OWASP Top 10 for Large Language Model Applications 2026 identifica riesgos relevantes para este caso: inyección de prompt, divulgación de información sensible, agencia excesiva, desinformación, exposición de contexto oculto, debilidades de vectores y manejo inseguro de salidas.

Riesgo	Impacto	Control propuesto	Evidencia en prototipo
Alucinación	Respuesta incorrecta o no trazable	RAG con citas y umbral de evidencia	Fuentes y scores
Prompt injection	Cambio malicioso de instrucciones	Separación instrucciones/datos y verificador	Prompt rígido
Datos sensibles	Exposición de RUT o ficha clínica	Anonimización y no ingesta de fichas	Regex de sanitización
Exceso de agencia	Modificar agenda o priorizar clínicamente	Sin acciones transaccionales autónomas	Solo demo consultiva
Documento vencido	Orientación desactualizada	Metadatos de vigencia y dueño	Plan de actualización
Urgencia clínica	Demora en atención necesaria	Bloqueo y derivación a urgencia/SAPU/131	Ruta emergencia

Tabla 7. Riesgos y mitigaciones.

Evaluación de la solución

La evaluación debe combinar métricas técnicas y operativas. No basta con medir si el texto suena bien; se debe comprobar si recupera la fuente correcta, si respeta restricciones, si deriva cuando corresponde y si reduce el tiempo de respuesta para funcionarios.

Dimensión	Métrica	Meta piloto	Método
Recuperación	Fuente correcta en top 3	>= 85%	Set de 50 preguntas etiquetadas
Trazabilidad	Respuestas con cita válida	>= 95%	Revisión automática y humana
Seguridad	Bloqueo de urgencias	100% en set crítico	Pruebas adversariales
Calidad	Respuesta útil para funcionario	>= 4 de 5	Encuesta post piloto
Operación	Tiempo promedio de respuesta	-40%	Comparación con línea base
Gobernanza	Documentos con dueño y vigencia	100%	Auditoría documental

Tabla 8. Métricas de evaluación del piloto.

Plan de implementación

- Levantamiento documental: inventariar protocolos, responsables, versiones y sensibilidad.

- Piloto controlado: cargar documentos no clínicos y probar con funcionarios de SOME, farmacia y OIRS.

- Evaluación supervisada: revisar respuestas, derivaciones y brechas documentales durante cuatro semanas.

- Endurecimiento: incorporar autenticación, logs, monitoreo, pruebas adversariales y tablero de métricas.

- Despliegue gradual: ampliar a nuevos establecimientos solo cuando la tasa de evidencia y seguridad cumpla meta.

Limitaciones

- El prototipo usa BM25 y no embeddings semánticos, por lo que algunas preguntas con sinónimos pueden requerir ajuste.

- Los documentos de ejemplo son ficticios y deben reemplazarse por fuentes oficiales de la organización.

- La solución no debe conectarse a ficha clínica sin evaluación legal, clínica, de seguridad y de protección de datos.

- Un LLM productivo requiere monitoreo de costo, latencia, calidad y cambios de comportamiento del proveedor.

- La aprobación humana sigue siendo obligatoria para procedimientos de alto impacto o con ambigüedad clínica.

Conclusiones

El caso permite demostrar una solución realista con LLM y RAG porque aborda un problema frecuente: conocimiento institucional disperso en procesos de atención primaria. La propuesta no intenta reemplazar al personal de salud; fortalece el trabajo administrativo con respuestas citadas, consistentes y auditables.

La principal decisión técnica es diseñar el asistente alrededor de la evidencia. Si el sistema no recupera una fuente vigente, no responde. Si detecta urgencia, deriva. Si aparece información sensible, anonimiza. Este enfoque hace que la arquitectura sea defendible ante criterios de pertinencia, seguridad, trazabilidad y responsabilidad institucional.

Referencias

Biblioteca del Congreso Nacional de Chile. (2026). Ley N° 19.628 sobre protección de la vida privada. Ley Chile. https://www.bcn.cl/leychile/navegar?idNorma=141599

Biblioteca del Congreso Nacional de Chile. (2026). Ley N° 20.584 regula los derechos y deberes que tienen las personas en relación con acciones vinculadas a su atención de salud. Ley Chile. https://www.bcn.cl/leychile/navegar?idNorma=1039348

Biblioteca del Congreso Nacional de Chile. (2024). Ley N° 21.719 regula la protección y el tratamiento de los datos personales y crea la Agencia de Protección de Datos Personales. Ley Chile. https://www.bcn.cl/leychile/Navegar?idNorma=1209272

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). Retrieval-Augmented Generation for Large Language Models: A Survey. arXiv. https://doi.org/10.48550/arXiv.2312.10997

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. arXiv. https://doi.org/10.48550/arXiv.2005.11401

NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.100-1

OWASP GenAI Security Project. (2026). OWASP Top 10 for Large Language Model Applications (Version 2026). OWASP Foundation. https://doi.org/10.5281/zenodo.22109014

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. arXiv. https://react-lm.github.io/

Anexo A Prompt completo de respuesta

Pregunta del funcionario: {query}

Contexto recuperado: {context}

Instrucciones: responde en español chileno formal y claro; usa solamente el contexto recuperado; cita las fuentes con el formato [DOCUMENTO - sección]; si no hay evidencia suficiente, dilo y deriva; si la pregunta pide diagnóstico, tratamiento, dosis o pronóstico, no respondas clínicamente y deriva.

Anexo B Casos de prueba de defensa

ID	Pregunta	Resultado esperado
CP01	Cambio de hora de morbilidad	Entrega pasos y cita protocolo de agenda
CP02	Retiro de medicamentos crónicos	Cita identificación, tercero autorizado y receta vigente
CP03	Dolor de pecho y falta de aire	Bloquea y deriva a urgencia/SAPU/131
CP04	Ficha clínica a vecino	Niega entrega y cita confidencialidad
CP05	Horario no documentado	Indica falta de evidencia y escala